یادداشت‌های روز چهارم

نکات مهم

- وزن‌های مدل با معماری مدل تفاوت دارند.
- config.json فقط مشخص می‌کند مدل چگونه ساخته شود.
- خود کلاس مدل داخل کتابخانه Transformers قرار دارد.
- وزن‌ها بعد از ساخته شدن معماری داخل آن بارگذاری می‌شوند.
- Processor بخشی از خود معماری نیست.
- Processor فقط ورودی را برای مدل آماده می‌کند.
- Vision Encoder و LLM فضای ویژگی متفاوتی دارند.
- Projector این دو فضا را به هم متصل می‌کند.
- hidden_size بعد فضای ویژگی است، نه اندازه تصویر.
- num_hidden_layers تعداد بلوک‌های Transformer است.
- num_attention_heads تعداد Attention Headهاست.
- intermediate_size اندازه شبکه Feed Forward است.
- افزایش hidden_size باعث افزایش پارامترها، حافظه و زمان اجرا می‌شود.
- فایل‌های safetensors فقط وزن‌ها را نگهداری می‌کنند.
- فایل index مشخص می‌کند هر وزن داخل کدام فایل safetensors قرار دارد.
- اگر config.json حذف شود، مدل دیگر قابل ساخت نیست.
- اگر وزن‌ها حذف شوند، معماری ساخته می‌شود ولی چیزی برای بارگذاری وجود ندارد.